

# Redes Neuronales Monocapa III

## Modelos de la computación (Aprendizaje supervisado)

Francisco Fernández Navarro

Departamento de Lenguajes y Ciencias de la Computación  
Área: Ciencias de la Computación e Inteligencia Artificial



## 1 ADALINA

- Introducción
- Modelo funcional
- Problema de optimización
- Estimación de parámetros para la implementación en línea
- Estimación de parámetros para la implementación por lotes
- Ejemplos de implementación
- Versión analítica de ADALINA

## 2 Neuronas con salida continua

- Modelo funcional
- Problema de optimización y estimación de parámetros

# ADALINA

## Breve reseña histórica

- El término “Adaline” es una abreviatura de “Adaptive Linear Neuron” (Neurona Lineal Adaptativa).
- Modelo de red neuronal artificial que fue desarrollado por Bernard Widrow y Ted Hoff en Stanford University en la década de 1960.

## Fundamentación

- El Adaline se desarrolló como una alternativa del Perceptrón de Frank Rosenblatt.
- A diferencia del Perceptrón, el Adaline utiliza una función de activación lineal y realiza ajustes continuos en los pesos de las conexiones entre las neuronas para minimizar el error de predicción.

## 1 ADALINA

- Introducción
- **Modelo funcional**
- Problema de optimización
- Estimación de parámetros para la implementación en línea
- Estimación de parámetros para la implementación por lotes
- Ejemplos de implementación
- Versión analítica de ADALINA

## 2 Neuronas con salida continua

- Modelo funcional
- Problema de optimización y estimación de parámetros

## Modelo funcional

La salida de la unidad para un patrón  $n$ -ésimo,  $\mathbf{x}_n \in \mathbb{R}^K$  es:


$$\hat{y}(\mathbf{x}_n) = f(\mathbf{x}_n) = \sum_{k=1}^K w_k x_{nk} - \theta, \quad (1)$$

donde  $\mathbf{w} \in \mathbb{R}^K$  son los pesos con los que se ponderan los valores de entrada (conocidos como **pesos sinápticos**) y el parámetro  $\theta$  es el **umbral o sesgo** de la unidad de procesamiento. Alternativamente:

$$\hat{y}(\mathbf{x}_n) = f(\mathbf{x}_n) = \sum_{k=1}^{K+1} w_k x_{nk}, \quad (2)$$

considerando una entrada adicional con valor  $x_{nK+1} = -1$  ( $\forall n, n = 1, \dots, N$ ) cuyo peso sináptico  $w_{K+1} = \theta$ .

## ADALINA con 5 entradas



## 1 ADALINA

- Introducción
- Modelo funcional
- **Problema de optimización**
- Estimación de parámetros para la implementación en línea
- Estimación de parámetros para la implementación por lotes
- Ejemplos de implementación
- Versión analítica de ADALINA

## 2 Neuronas con salida continua

- Modelo funcional
- Problema de optimización y estimación de parámetros

## Problema de optimización

- Los parámetros del modelo se estiman a través del siguiente problema de optimización:

$$\min_{\mathbf{w} \in \mathbb{R}^{K+1}} E(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^N (y_n - \hat{y}_n)^2 = \frac{1}{2} \sum_{n=1}^N \left( y_n - \sum_{k=1}^{K+1} w_k x_{nk} \right)^2$$

donde  $\mathbf{w} = (w_1, \dots, w_{K+1})$  es el vector de pesos a estimar.

- Minimización error cuadrático medio.
- Se trata de determinar los pesos sinápticos que consiguen que las salidas de la red sean lo más parecidas a las salidas deseadas para el conjunto dado de patrones de entrenamiento.



## Cuestiones

- ¿Porqué los errores de aproximación están al cuadrado?
- ¿Por qué se elevan al cuadrado los errores individuales al calcular el ECM en lugar de tomar el valor absoluto de los errores?
- ¿Cuál es el efecto de los valores atípicos (outliers) en el ECM?  
¿Por qué el ECM puede ser sensible a los valores atípicos?
- ¿Cuáles son algunas ventajas y desventajas de utilizar el ECM como métrica de evaluación de un modelo de regresión?

## 1 ADALINA

- Introducción
- Modelo funcional
- Problema de optimización
- Estimación de parámetros para la implementación en línea
- Estimación de parámetros para la implementación por lotes
- Ejemplos de implementación
- Versión analítica de ADALINA

## 2 Neuronas con salida continua

- Modelo funcional
- Problema de optimización y estimación de parámetros

## Estimación de parámetros. Cuestiones previas

- Vamos a seguir para la estimación un procedimiento iterativo, de tal forma que los parámetros serán modificados en unas iteraciones que irán de la 1 a la  $I$ , y en cada iteración los parámetros serán modificados patrón a patrón,  $n = 1, \dots, N$ .
- Para ello es necesario modificar la formulación de base para indicar que  $\hat{y}_n(i)$ , es la estimación del patrón  $n$ -ésimo en la iteración  $i$ -ésima, y que  $w_k(i, n)$  es el valor del vector de pesos en la dimensión  $k$ -ésima, en la iteración  $i$ -ésima y en el patrón  $n$ -ésimo.

## Estimación de parámetros. Cuestiones previas

- El patrón en la iteración  $i$ , en su dimensión  $k$ , será modificado debido al patrón  $n$  en función de la siguiente ecuación:

$$w_k(i, n + 1) = w_k(i, n) + \Delta w_k(i, n), \quad (3)$$

- La varianción de dicho término quedará definida como:

$$\Delta w_k(i, n) = -\eta \frac{\partial E(\mathbf{w})}{\partial w_k(i, n)} = \eta(y_n - \hat{y}_n(i))x_{nk},$$

donde  $\hat{y}_n(i) = \sum_{k=1}^{K+1} w_k(i, n)x_{nk}$

- El parámetro  $\eta$  (**tasa de aprendizaje**) controla la longitud del paso que vamos a dar en la dirección opuesta del gradiente.

## ADALINA-EN LINEA ( $\mathcal{D}$ , $\eta > 0$ ):

- 1:  $\mathbf{X} \leftarrow (\mathbf{X} - \mathbf{1}_N) \in \mathbb{R}^{N \times (K+1)}$
- 2: **for**  $k = 1$  until  $K + 1$  **do**
- 3:    $w_k(1, 0) \leftarrow 2 \times \text{rand}() - 1, 0 \leq \text{rand}() < 1$   
     $(\mathbf{w}(1, 0) = (w_1(1, 0), \dots, w_{K+1}(1, 0)))$ .
- 4: **end for**
- 5: **for**  $i = 1$  until  $I$  **do**
- 6:   **for**  $n = 1$  until  $N$  **do**
- 7:      $\hat{y}_n(i) \leftarrow \sum_{k=1}^{K+1} w_k(i, n)x_{nk}$
- 8:     **for**  $k = 1$  until  $K + 1$  **do**
- 9:        $\Delta w_k(i, n) \leftarrow \eta(y_n - \hat{y}_n(i))x_{nk}$
- 10:        $w_k(i, n) \leftarrow w_k(i, n - 1) + \Delta w_k(i, n)$ .
- 11:     **end for**
- 12:   **end for**
- 13: **end for**

## 1 ADALINA

- Introducción
- Modelo funcional
- Problema de optimización
- Estimación de parámetros para la implementación en línea
- Estimación de parámetros para la implementación por lotes
- Ejemplos de implementación
- Versión analítica de ADALINA

## 2 Neuronas con salida continua

- Modelo funcional
- Problema de optimización y estimación de parámetros

## Adalina por lotes

- **Idea:** Introducir los  $N$  patrones directamente y comparar las salidas de la red con las salidas deseadas, pasando entonces a actualizar los pesos sinápticos.
- La modificación de los pesos sinápticos se hace tomando como función de error el error medio, por lo que el problema de optimización queda como:

$$\min_{\mathbf{w} \in \mathbb{R}^{K+1}} E(\mathbf{w}) = \frac{1}{2N} \sum_{n=1}^N (y_n - \hat{y}_n)^2 = \frac{1}{2N} \sum_{n=1}^N \left( y_n - \sum_{k=1}^{K+1} w_k x_{nk} \right)^2$$

## Adalina por lotes

- No necesitamos iterar por patrón por lo que tendremos parámetros denotados como:  $w_k(i)$  (valor del peso sináptico en su dimensión  $k$  en la iteración  $i$ ).
- La regla de aprendizaje quedaría como:

$$\Delta w_k(i) = -\eta \frac{\partial E(\mathbf{w})}{\partial w_k(i)} = \frac{\eta}{N} \sum_{n=1}^N (y_n - \hat{y}_n(i)) x_{nk},$$



# Flujo algorítmico - Algoritmo por lotes

**ADALINA-POR LOTES** ( $\mathcal{D}, \eta > 0$ ):

```
1:  $\mathbf{X} \leftarrow (\mathbf{X} - \mathbf{1}_N) \in \mathbb{R}^{N \times (K+1)}$ 
2: for  $k = 1$  until  $K + 1$  do
3:    $w_k(0) \leftarrow 2 \times \text{rand}() - 1, (\mathbf{w}(0) = (w_1(0), \dots, w_{K+1}(0)))$ .
4: end for
5: for  $i = 1$  until  $I$  do
6:   for  $k = 1$  until  $K + 1$  do
7:      $\Delta w_k(i) \leftarrow 0$ 
8:   end for
9:   for  $n = 1$  until  $N$  do
10:     $\hat{y}_n(i) \leftarrow \sum_{k=1}^{K+1} w_k(i, n) x_{nk}$ 
11:    for  $k = 1$  until  $K + 1$  do
12:       $\Delta w_k(i) \leftarrow \Delta w_k(i) + (y_n - \hat{y}_n(i)) x_{nk}$ 
13:    end for
14:  end for
15:   $\Delta w_k(i) \leftarrow \frac{\eta \Delta w_k(i)}{N}$ 
16:  for  $k = 1$  until  $K + 1$  do
17:     $w_k(i) \leftarrow w_k(i - 1) + \Delta w_k(i)$ .
18:  end for
19: end for
```

## 1 ADALINA


- Introducción
- Modelo funcional
- Problema de optimización
- Estimación de parámetros para la implementación en línea
- Estimación de parámetros para la implementación por lotes
- Ejemplos de implementación
- Versión analítica de ADALINA

## 2 Neuronas con salida continua

- Modelo funcional
- Problema de optimización y estimación de parámetros


# Ejemplo ADALINA AND

t	x1	x2	-1	Z	Y	w1	w2	rho
						0	0	0
1	1	1	-1	1	0,00	0,10	0,10	-0,10
2	1	-1	-1	-1	0,10	-0,01	0,21	0,01
3	-1	1	-1	-1	0,21	0,11	0,09	0,13
4	-1	-1	-1	-1	-0,33	0,18	0,16	0,20
5	1	1	-1	1	0,14	0,26	0,24	0,11
6	1	-1	-1	-1	-0,09	0,17	0,33	0,20
7	-1	1	-1	-1	-0,04	0,27	0,24	0,30
8	-1	-1	-1	-1	-0,80	0,29	0,26	0,32
9	1	1	-1	1	0,23	0,37	0,33	0,24
10	1	-1	-1	-1	-0,21	0,29	0,41	0,32
11	-1	1	-1	-1	-0,19	0,37	0,33	0,40
12	-1	-1	-1	-1	-1,10	0,36	0,32	0,39
13	1	1	-1	1	0,29	0,43	0,39	0,32
14	1	-1	-1	-1	-0,28	0,36	0,47	0,39
15	-1	1	-1	-1	-0,28	0,43	0,39	0,46
16	-1	-1	-1	-1	-1,28	0,40	0,37	0,43
17	1	1	-1	1	0,33	0,47	0,43	0,37
18	1	-1	-1	-1	-0,33	0,40	0,50	0,43
19	-1	1	-1	-1	-0,34	0,47	0,43	0,50
20	-1	-1	-1	-1	-1,40	0,43	0,39	0,46



# Ejemplo ADALINA XOR

t	x1	x2	-1	Z	Y	w1	w2	rho
						0	0	0
1	1	1	-1	-1	0,00	-0,10	-0,10	0,10
2	1	-1	-1	1	-0,10	0,01	-0,21	-0,01
3	-1	1	-1	1	-0,21	-0,11	-0,09	-0,13
4	-1	-1	-1	-1	0,33	0,02	0,04	0,00
5	1	1	-1	-1	0,06	-0,08	-0,06	0,11
6	1	-1	-1	1	-0,13	0,03	-0,18	0,00
7	-1	1	-1	1	-0,20	-0,09	-0,06	-0,12
8	-1	-1	-1	-1	0,27	0,04	0,07	0,00
9	1	1	-1	-1	0,10	-0,07	-0,04	0,11
10	1	-1	-1	1	-0,15	0,04	-0,15	0,00
11	-1	1	-1	1	-0,19	-0,08	-0,03	-0,12
12	-1	-1	-1	-1	0,23	0,04	0,09	0,00
13	1	1	-1	-1	0,13	-0,07	-0,02	0,12
14	1	-1	-1	1	-0,16	0,05	-0,14	0,00
15	-1	1	-1	1	-0,19	-0,07	-0,02	-0,12
16	-1	-1	-1	-1	0,21	0,05	0,10	0,00
17	1	1	-1	-1	0,15	-0,06	-0,01	0,12
18	1	-1	-1	1	-0,17	0,05	-0,13	0,00
19	-1	1	-1	1	-0,18	-0,07	-0,01	-0,12
20	-1	-1	-1	-1	0,20	0,05	0,11	0,00



## 1 ADALINA

- Introducción
- Modelo funcional
- Problema de optimización
- Estimación de parámetros para la implementación en línea
- Estimación de parámetros para la implementación por lotes
- Ejemplos de implementación
- Versión analítica de ADALINA

## 2 Neuronas con salida continua

- Modelo funcional
- Problema de optimización y estimación de parámetros

## Adalina versión no iterativa

- Vamos a estimar los parámetros sin la necesidad de iterar.
- El conjunto de entrada será extendido con un vector columna de -1s al final de la matriz original ( $\mathbf{X} = (\mathbf{X} \ - \mathbf{1}_N) \in \mathbb{R}^{N \times (K+1)}$ ).
- La variable dependiente en forma matricial será definida como  $\mathbf{Y} = (y_1, \dots, y_n) \in \mathbb{R}^N$ .
- El problema de optimización quedaría como:

$$\min_{\mathbf{w} \in \mathbb{R}^{K+1}} E(\mathbf{w}) = \|\mathbf{Y} - \mathbf{X}\mathbf{w}\|^2 = (\mathbf{Y} - \mathbf{X}\mathbf{w})'(\mathbf{Y} - \mathbf{X}\mathbf{w})$$

donde  $\mathbf{w} = (w_1, \dots, w_K, \theta) \in \mathbb{R}^{K+1}$ .

## Adalina versión no iterativa

- Expandimos la función de error:

$$||\mathbf{Y} - \mathbf{X}\mathbf{w}||^2 = \mathbf{Y}'\mathbf{Y} - 2\mathbf{w}'\mathbf{X}'\mathbf{Y} + \mathbf{w}'\mathbf{X}'\mathbf{X}\mathbf{w}$$

- Derivamos e igualamos a cero:

$$\frac{\partial E(\mathbf{w})}{\partial \mathbf{w}} = -2\mathbf{X}'\mathbf{Y} + 2\mathbf{X}'\mathbf{X}\mathbf{w} = 0,$$

por lo que

$$\mathbf{X}'\mathbf{X}\mathbf{w} = \mathbf{X}'\mathbf{Y},$$

y por tanto

$$\mathbf{w} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}.$$

## ADALINA-ANALITICO ( $\mathcal{D}$ ):

- 1:  $\mathbf{X} \leftarrow (\mathbf{X} - \mathbf{1}_N) \in \mathbb{R}^{N \times (K+1)}$
- 2:  $\mathbf{w} \leftarrow (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}.$



## 1 ADALINA

- Introducción
- Modelo funcional
- Problema de optimización
- Estimación de parámetros para la implementación en línea
- Estimación de parámetros para la implementación por lotes
- Ejemplos de implementación
- Versión analítica de ADALINA

## 2 Neuronas con salida continua

- Modelo funcional
- Problema de optimización y estimación de parámetros

## Modelo funcional

- La salida de la unidad para un patrón  $n$ -ésimo,  $\mathbf{x}_n \in \mathbb{R}^K$  es:

$$\hat{y}(\mathbf{x}_n) = g \left( \sum_{k=1}^{K+1} w_k x_{nk} \right), \quad (4)$$

donde  $\mathbf{w} \in \mathbb{R}^K$  son los pesos con los que se ponderan los valores de entrada y  $g(\cdot)$  es la función de transferencia.


- La función de transferencia va a ser una función diferenciable y no decreciente.

## Tipos de función de transferencia


- La función logística:  $g(x) = \frac{1}{1+\exp(-2\beta x)}$ . Función de aplastamiento,  $g : \mathbb{R} \rightarrow [0, 1]$ . El parámetro de ganancia  $\beta$  controla la pendiente de la curva. Derivada muy simple:  
 $g'(x) = 2\beta g(x)(1 - g(x))$ .
- La función tangente hiperbólica:  $g(x) = \tanh(\beta x) = \frac{e^{\beta x} - e^{-\beta x}}{e^{\beta x} + e^{-\beta x}}$ . Función de aplastamiento,  $g : \mathbb{R} \rightarrow [-1, 1]$ . Derivada muy simple:  
 $g'(x) = \beta(1 - g(x)^2)$

# Representación gráfica - Funciones Logística y Tangente Hiperbólica

## Función Logística



## Función Tangente Hiperbólica



## 1 ADALINA

- Introducción
- Modelo funcional
- Problema de optimización
- Estimación de parámetros para la implementación en línea
- Estimación de parámetros para la implementación por lotes
- Ejemplos de implementación
- Versión analítica de ADALINA

## 2 Neuronas con salida continua

- Modelo funcional
- Problema de optimización y estimación de parámetros

## Problema de optimización

- Los parámetros del modelo se estiman a través del siguiente problema de optimización:

$$\min_{\mathbf{w} \in \mathbb{R}^{K+1}} E(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^N (y_n - \hat{y}_n)^2 = \frac{1}{2} \sum_{n=1}^N \left( y_n - g \left( \sum_{k=1}^{K+1} w_k x_{nk} \right) \right)^2.$$

- Por lo que en el aprendizaje en línea, la variación viene definida como:

$$\Delta w_k(i, n) = -\eta \frac{\partial E(\mathbf{w})}{\partial w_k(i, n)} = \eta (y_n - \hat{y}_n(i)) g' \left( \sum_{k=1}^{K+1} w_k x_{nk} \right) x_{nk}.$$

- Para el aprendizaje por lotes usamos de función de error el error cuadrático promedio (al igual que hicimos con el ADALINA).

¡Gracias por vuestra atención!

